Guía de Laboratorio

Laboratorio 01

Predicción multiclase del deterioro cognitivo mediante métodos de ensamble

Asignatura: *Deep Learning*

Profesor: Dr. Juan Bekios Calfa

Ayudantes: Srta. Constanza Quintana Alday

Fecha de publicación: 01/03/2026

Fecha de entrega: 15/03/2026

1. Introducción

En esta guía de laboratorio se abordará un problema de clasificación multiclase aplicado a la predicción del deterioro cognitivo a partir de datos neuropsicológicos. El propósito central es que el estudiantado diseñe, implemente y compare distintas estrategias de aprendizaje de ensamble en un contexto donde el conjunto de datos disponible presenta dos desafíos frecuentes en problemas reales: una cantidad reducida de muestras y una distribución desbalanceada entre clases.

La detección y caracterización del deterioro cognitivo constituye un problema de interés en salud y en ciencia de datos, ya que involucra la identificación de patrones complejos en variables observadas de pacientes o individuos evaluados mediante instrumentos especializados. En este laboratorio, el problema se formulará estrictamente como una tarea de clasificación multiclase, donde cada observación pertenece a una única categoría de deterioro cognitivo.

La guía se enmarca en el estudio de técnicas de ensamble, entendidas como estrategias que combinan varios modelos para mejorar la calidad de la predicción. En particular, se trabajará con tres enfoques ampliamente utilizados: Bagging, Boosting y Stacking. La comparación entre estas técnicas permitirá analizar cómo cambian los resultados cuando los datos son pocos y las clases no tienen una representación equilibrada.

2. Contexto del problema

El deterioro cognitivo corresponde a una disminución en funciones mentales superiores como la memoria, la atención, el lenguaje, la orientación y el razonamiento. En distintos contextos clínicos, su evaluación es relevante para apoyar diagnósticos, seguimientos y decisiones de tratamiento. Desde una perspectiva computacional, este problema puede plantearse como una tarea supervisada en la que, a partir de un conjunto de variables predictoras, se intenta estimar la categoría o nivel de deterioro asociado a un individuo.

Este laboratorio trabajará con un conjunto de datos en que las variables predictoras representan resultados o características derivadas de evaluaciones cognitivas. La variable objetivo corresponde a categorías de deterioro cognitivo, por lo que el problema no debe abordarse como clasificación multilabel. Cada instancia posee una sola etiqueta de clase.

Este escenario presenta dificultades metodológicas importantes. Por una parte, el número de muestras es acotado, lo que limita la cantidad de información disponible para ajustar modelos complejos y aumenta el riesgo de sobreajuste. Por otra parte, las clases no se distribuyen

de manera uniforme, de modo que algunas categorías cuentan con muchos menos ejemplos que otras. Esto implica que una evaluación basada únicamente en accuracy puede resultar engañosa, pues un modelo podría favorecer las clases mayoritarias y aun así reportar un desempeño aparentemente aceptable.

En consecuencia, el laboratorio no se orienta solo a entrenar clasificadores, sino a construir una metodología experimental rigurosa para comparar estrategias de ensamble en un problema multiclase con restricciones realistas de tamaño muestral y desbalance.

3. Objetivos

3.1. Objetivo general

Desarrollar y comparar modelos de clasificación multiclase para la predicción del deterioro cognitivo utilizando técnicas de ensamble del tipo Bagging, Boosting y Stacking.

3.2. Objetivos específicos

1. Comprender el problema de predicción del deterioro cognitivo como una tarea de clasificación multiclase.
2. Analizar la estructura del conjunto de datos y la distribución de la variable objetivo.
3. Diseñar un protocolo experimental apropiado para escenarios con pocas muestras.
4. Implementar un modelo basado en Bagging.
5. Implementar un modelo basado en Boosting.
6. Implementar un modelo basado en Stacking.
7. Incorporar una estrategia razonada para enfrentar el desbalance de clases.
8. Comparar el desempeño de los modelos mediante métricas adecuadas para clasificación multiclase.
9. Interpretar críticamente los resultados obtenidos.

4. Descripción general del laboratorio

Cada grupo deberá trabajar con el conjunto de datos entregado y desarrollar tres modelos de ensamble, uno por cada familia metodológica estudiada en la unidad. El trabajo experimental deberá estar acompañado de una justificación técnica de las decisiones adoptadas durante el proceso, incluyendo el protocolo de validación, la estrategia de preprocesamiento, el tratamiento del desbalance y los criterios de evaluación.

El énfasis del laboratorio estará en la metodología de trabajo. Por ello, no se solicita desarrollar teoría de clasificación multilabel ni incorporar métricas o interpretaciones asociadas a ese tipo de problema. Todo el desarrollo debe mantenerse dentro del marco de clasificación multiclase.

Adicionalmente, se espera que el desarrollo computacional del laboratorio esté organizado de manera modular. Esto implica estructurar el código en componentes con responsabilidades claras, evitando implementaciones monolíticas difíciles de mantener, depurar o reutilizar. La organización modular será considerada tanto como una buena práctica de ingeniería como un criterio formal de evaluación.

5. Metodología de trabajo

5.1. Exploración inicial de los datos

La primera etapa del trabajo consiste en examinar la estructura general del conjunto de datos. Para ello, se deberá identificar el número total de instancias, la cantidad de atributos predictivos, el tipo de variables presentes y la distribución de la variable objetivo.

Se deberá prestar especial atención a la frecuencia de ejemplos por clase, ya que esta revisión permitirá detectar el nivel de desbalance presente en el problema. Asimismo, será necesario identificar posibles valores faltantes, inconsistencias, atributos irrelevantes o diferencias de escala entre variables.

Esta etapa debe quedar documentada en el informe, no solo como una descripción superficial del conjunto de datos, sino como una base para justificar las decisiones metodológicas posteriores.

5.2. Preparación de los datos

Luego de la exploración, se deberá definir una estrategia de preparación del conjunto de datos. Esta puede incluir limpieza, transformación de variables, escalamiento, estandarización o codificación, según corresponda.

Toda transformación que dependa de los datos debe realizarse de manera cuidadosa para evitar fuga de información. En particular, si se utiliza escalamiento, balanceo o cualquier otro procedimiento basado en estadísticas del conjunto, este debe aplicarse exclusivamente sobre los datos de entrenamiento dentro de cada partición de validación.

La preparación no debe entenderse como un proceso mecánico, sino como una parte fundamental del experimento, que puede influir de manera importante en el comportamiento de los modelos de ensamble.

5.3. Diseño experimental

Debido a que el conjunto de datos es pequeño, no resulta adecuado depender de una sola partición entrenamiento-prueba. Se deberá utilizar un protocolo de validación que permita aprovechar mejor la información disponible y obtener una estimación más estable del rendimiento.

Se recomienda emplear validación cruzada estratificada, de manera que la proporción relativa de las clases se mantenga de la mejor forma posible en cada partición. Esto es especialmente importante en escenarios desbalanceados.

Todos los modelos deberán evaluarse bajo el mismo esquema experimental. Esta condición es esencial para que la comparación entre Bagging, Boosting y Stacking sea válida.

5.4. Tratamiento del desbalance de clases

Uno de los principales desafíos del laboratorio es el desbalance de clases. Cada grupo deberá definir una estrategia explícita para enfrentar este problema. Entre las alternativas posibles se encuentran el uso de pesos por clase, técnicas de sobremuestreo, submuestreo o una combinación razonada de estas estrategias.

La decisión adoptada deberá ser consistente con el tamaño del conjunto de datos y con la distribución observada de la variable objetivo. Además, el informe deberá explicar claramente en qué etapa del proceso se aplicó la estrategia seleccionada.

No basta con mencionar que el conjunto de datos está desbalanceado. Se espera que el diseño experimental incorpore una respuesta metodológica concreta frente a esta situación.

5.5. Construcción de modelos

Cada grupo deberá implementar tres modelos de ensamble.

5.5.1. Modelo basado en Bagging

Se deberá desarrollar un modelo de Bagging utilizando un clasificador base adecuado para el problema. Esta estrategia busca reducir la varianza mediante el entrenamiento de múltiples modelos sobre subconjuntos remuestreados del conjunto de entrenamiento y la posterior agregación de sus predicciones.

La elección del clasificador base deberá ser justificada en función de las características del problema y del tamaño del conjunto de datos.

5.5.2. Modelo basado en Boosting

Se deberá implementar un modelo de Boosting en el que una secuencia de clasificadores aprenda progresivamente, concentrando mayor atención en las instancias difíciles de clasificar. En esta parte se espera que el estudiantado discuta tanto las ventajas potenciales de esta técnica como su posible sensibilidad al sobreajuste cuando el número de muestras es reducido.

5.5.3. Modelo basado en Stacking

Se deberá implementar un modelo de Stacking compuesto por varios clasificadores base y un meta-clasificador que combine sus salidas. La selección de los modelos base y del clasificador final deberá estar fundamentada. El interés de esta estrategia radica en integrar distintas perspectivas de modelamiento para obtener una predicción final potencialmente más robusta.

5.6. Evaluación del desempeño

La evaluación de los modelos deberá considerar que la métrica accuracy no es suficiente por sí sola en un problema multiclase con desbalance. Por ello, cada grupo deberá reportar

métricas que permitan una interpretación más completa del rendimiento.

Se recomienda incluir, al menos, accuracy, precision macro, recall macro y F1-score macro, junto con la matriz de confusión. También es deseable analizar el comportamiento por clase, con especial atención a las categorías minoritarias.

El objetivo de esta etapa no es únicamente identificar el mejor valor numérico, sino comprender cómo responde cada técnica frente a las características particulares del problema.

5.7. Comparación e interpretación de resultados

Una vez evaluados los tres modelos, se deberá realizar una comparación crítica entre las estrategias de Bagging, Boosting y Stacking. Esta comparación debe considerar no solo el rendimiento global, sino también la estabilidad, la sensibilidad al desbalance, el comportamiento frente a clases minoritarias y la complejidad general de cada enfoque.

La discusión debe estar centrada en el problema de predicción del deterioro cognitivo y en las implicancias metodológicas de trabajar con pocos datos. No se espera una comparación superficial, sino una interpretación argumentada de los resultados obtenidos.

5.8. Arquitectura de módulos propuesta

Se recomienda organizar la solución mediante una arquitectura modular, donde cada módulo cumpla una responsabilidad bien definida dentro del flujo experimental. Esta forma de trabajo facilita la mantención del código, la reutilización de componentes, la depuración y la trazabilidad del proceso completo.

Una arquitectura mínima sugerida puede considerar los siguientes módulos:

- **Carga de datos:** encargado de leer el conjunto de datos y verificar su integridad básica.
- **Preprocesamiento:** responsable de limpieza, selección de variables, transformación y escalamiento.
- **Balanceo:** módulo destinado a aplicar estrategias de pesos, sobremuestreo o submuestreo dentro del protocolo de validación.
- **Modelos:** implementación separada para Bagging, Boosting y Stacking.

- **Evaluación:** cálculo de métricas, matrices de confusión y resúmenes comparativos.
- **Visualización y reporte:** generación de tablas, gráficos y resultados exportables para el informe.
- **Archivo principal:** coordinación general del flujo experimental.

Esta propuesta no es obligatoria en su forma exacta, pero sí se espera una separación lógica similar entre componentes.

5.9. Jerarquía de directorios propuesta

A modo de referencia, una posible organización del proyecto podría ser la siguiente:

```
laboratorio_01/
|
|-- data/
|   |-- raw/
|   |-- processed/
|   `-- outputs/
|
|-- notebooks/
|   `-- exploracion.ipynb
|
|-- src/
|   |-- main.py
|   |-- config.py
|   |-- data_loader.py
|   |-- preprocessing.py
|   |-- balancing.py
|   |-- bagging_model.py
|   |-- boosting_model.py
|   |-- stacking_model.py
|   |-- evaluation.py
|   |-- visualization.py
|   `-- utils.py
|
```

```
|-- reports/
|   |-- figuras/
|   `-- tablas/
|
|-- requirements.txt
`-- README.md
```

Esta estructura permite distinguir claramente entre datos, código fuente, experimentación exploratoria, resultados y documentación del proyecto.

5.10. Ejemplo de arquitectura en TikZ

La siguiente figura muestra un ejemplo simple del flujo modular propuesto:

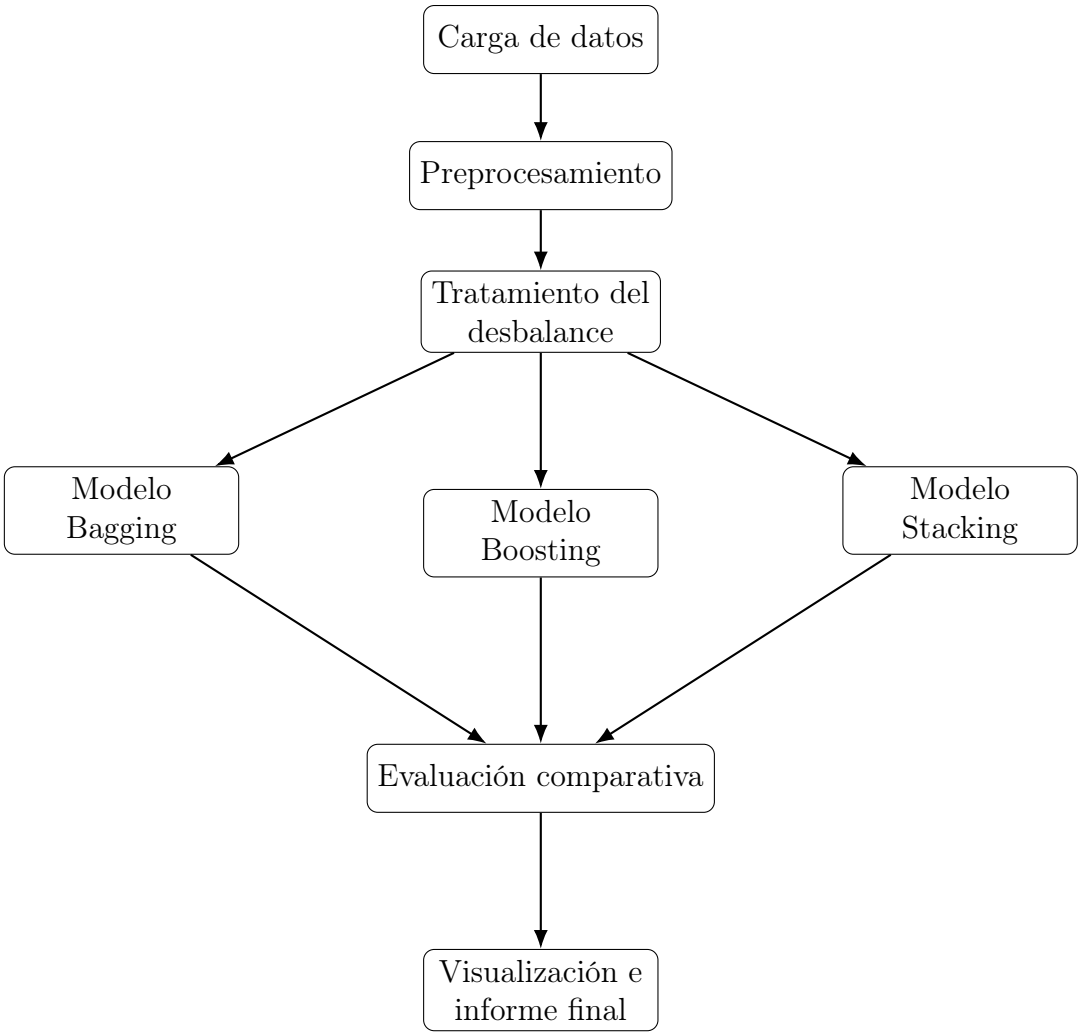

Figura 1: Ejemplo de flujo modular del laboratorio.

5.11. Ejemplo de organización interna del módulo `src` en TikZ

También es posible representar de forma esquemática la organización del código fuente:

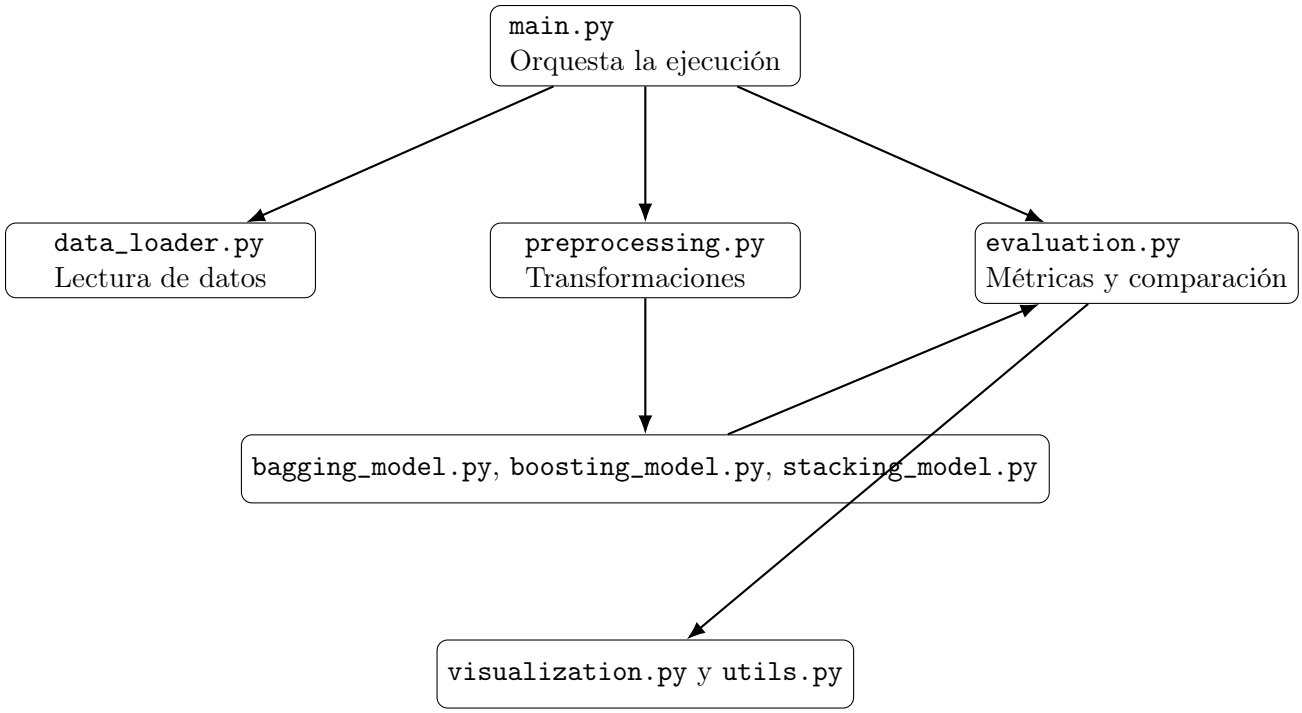

Figura 2: Ejemplo de descomposición modular del código fuente.

6. Actividades a desarrollar

Cada grupo deberá desarrollar las siguientes actividades:

1. Describir el problema de predicción del deterioro cognitivo como una tarea de clasificación multiclase.
2. Analizar el conjunto de datos y caracterizar la distribución de la variable objetivo.
3. Definir y justificar el protocolo experimental.
4. Implementar un modelo basado en Bagging.
5. Implementar un modelo basado en Boosting.
6. Implementar un modelo basado en Stacking.
7. Aplicar una estrategia para enfrentar el desbalance de clases.
8. Evaluar los tres modelos utilizando el mismo procedimiento.

9. Comparar e interpretar los resultados obtenidos.
10. Elaborar conclusiones metodológicas sobre el problema trabajado.
11. Organizar la solución computacional siguiendo una estructura modular coherente.

7. Estructura sugerida del informe

El informe deberá incluir al menos las siguientes secciones:

1. Introducción.
2. Contexto del problema.
3. Descripción del conjunto de datos.
4. Metodología de trabajo.
5. Arquitectura de módulos propuesta.
6. Modelos implementados.
7. Resultados experimentales.
8. Discusión.
9. Conclusiones.

La redacción debe ser clara, técnica y coherente con el trabajo desarrollado. Toda afirmación importante debe estar respaldada por evidencia empírica proveniente de los experimentos.

8. Instrucciones de entrega

La entrega del laboratorio deberá considerar los siguientes elementos:

- Código modular escrito en Python y librerías Sklearn que se ejecute localmente.
- Un informe en formato PDF.
- Tablas y figuras necesarias para respaldar la comparación experimental.

- Una conclusión final donde se indique qué técnica de ensamble resultó más adecuada para este problema y por qué.
- Una organización modular del código, con nombres de archivos y responsabilidades claramente identificables.

La fecha, hora y modalidad de entrega serán indicadas por el profesor en clases o por medio de la plataforma oficial del curso.

9. Recomendaciones

Se recomienda que cada grupo mantenga un flujo de trabajo ordenado, documentando con claridad las decisiones tomadas en cada etapa del experimento. También se sugiere verificar cuidadosamente que todas las transformaciones de datos se realicen dentro del protocolo de validación, evitando fuga de información.

Del mismo modo, se aconseja que la discusión final no se limite a presentar tablas de resultados, sino que incorpore una interpretación crítica del comportamiento de los modelos frente al tamaño reducido del conjunto de datos y al desbalance entre clases.

Además, se recomienda estructurar el código siguiendo principios básicos de modularidad. Separar lectura de datos, preprocesamiento, modelamiento y evaluación permitirá una mejor comprensión del flujo de trabajo y una implementación más cercana a prácticas reales de desarrollo en ciencia de datos.

10. Criterios generales de evaluación de la implementación

La actividad será evaluada considerando los siguientes aspectos:

Criterio	**Ponderación**
Comprensión del problema y contextualización	15 %
Análisis exploratorio y descripción de los datos	15 %
Diseño metodológico y protocolo experimental	15 %
Implementación de Bagging, Boosting y Stacking	20 %
Tratamiento del desbalance y evaluación comparativa	15 %
Modularización, organización del código y arquitectura propuesta	20 %